

İstatistiksel Testler: Kolay Anlatım Rehberi

Bu rehber, tezdeki her istatistiksel testi günlük hayattan benzetmelerle açıklar. Parantez içindeki terimler jüri karşısında kullanacağınız resmi isimlerdir.

KATMAN A: Veri Temizleme

Benzetme: Yemek yapmadan önce malzemeleri kontrol etmek gibi. Çürük domates varsa çıkarırsın, yoksa yemeğin tadı bozulur.

1. Eksik Veri Kontrolü (Little's MCAR Testi)

Günlük hayat: 150 kişiye anket yaptın. 8 kişi bazı soruları boş bırakmış. Şimdi soru şu: Bu 8 kişi rastgele mi boş bıraktı (mesela acele ettiler), yoksa belirli bir grup mu (mesela sadece acemiler zor soruları boş bıraktı)?

Neden önemli? Eğer sadece acemiler boş bıraktıysa ve sen bu verileri silersen, acemilerin verisi eksik kalır ve sonuçların "acemiler şöyle" dediğinde aslında eksik bilgiyle konuşmuş olursun.

Ne yaptık? Test yaptık, boş bırakmaların tamamen rastgele olduğunu kanıtladık. Yani güvenle silebildik.

Jüriye: "Eksik veriler MCAR testiyle rastgele olduğu doğrulandı, liste bazında silme uygulandı."

2. Uç Değer Tespiti (Z-skoru)

Günlük hayat: Sınıfta herkes 70-80 arası not alıyor, bir kişi 15 almış. Bu kişi ya kopya çekmeye çalışıp yakalanmış ya da yanlış sınava girmiş. Onu grubun ortalamasına katarsan, sınıf ortalaması yanlış düşer.

Neden önemli? Bir kişi görevi 60 dakikada bitirmişse (herkes 13-17 dakikada bitirirken), bu kişi muhtemelen ara vermiş veya sistemi açık bırakmış. Onu dahil edersen “ortalama süre” yanlış çıkar.

Ne yaptık? Her kişinin puanının, grubun ortalamasından kaç “adım” (standart sapma) uzak olduğunu hesapladık. 3.29 adımdan fazla uzak olanları “uç değer” olarak çıkardık.

Jüriye: “Aykırı değerler $z > 3.29$ kriteri ile tespit edilip analizden çıkarıldı.”

3. Çok Boyutlu Uç Değer (Mahalanobis Mesafesi)

Günlük hayat: Bir öğrenci hem devamsızlıkta sınırdaki, hem ödevlerde sınırdaki, hem sınavda sınırdaki. Tek tek baksan “tamam, sınırdaki” dersin. Ama üçüne birden bakınca “bu öğrenci sistemin dışında” olduğu ortaya çıkar.

Neden önemli? Z-skoru tek tek bakar. Ama birisi hem sürede biraz yüksek, hem yükte biraz yüksek, hem kalitede biraz düşükse — tek tek uç değil ama hepsi bir arada bakınca “bu kişi diğerlerinden çok farklı” olabilir.

Ne yaptık? Tüm değişkenleri aynı anda değerlendiren Mahalanobis mesafesini hesapladık. Çok uzak olanları çıkardık. Böylece 163 kişiden 13’ü elendi, 150 kişiyle devam ettik.

Jüriye: “Çok değişkenli aykırı değerler Mahalanobis mesafesi ile kontrol edildi.”

KATMAN B: Varsayım Kontrolleri

Benzetme: Araba kullanmadan önce lastik basıncını, yağı ve freni kontrol etmek gibi. Kontrol etmeden yola çıkarsan kaza yapabilirsin — ama kaza yapmasanız bile “kontrol etmediniz” diye ceza yersiniz.

4. Normal Dağılım Kontrolü (Shapiro-Wilk Testi)

Günlük hayat: Bir sınıfta not dağılımı genelde çan şeklindedir: çoğu kişi ortada, az kişi çok düşük veya çok yüksek alır. Ama bazen herkes ya çok iyi ya çok kötü alır (iki tepeli dağılım). İstatistiksel testlerin çoğu “çan şekli” varsayar.

Neden önemli? t-testi ve ANOVA, verilerin çan eğrisi gibi dağıldığını varsayar. Eğer dağılım çarpıksa (mesela herkes yüksek puan almış, tavan etkisi varsa), bu testlerin sonuçları güvenilmez olabilir.

Ne yaptık? Shapiro-Wilk testi ile kontrol ettik. Bazı değişkenlerde (bilişsel yük, kod kalitesi) çan eğrisi bozulmuştu. Bu yüzden hem normal testi (t-test) hem de “çan eğrisi gerektirmeyen” testi (Wilcoxon) yaptık. İkisi de aynı sonucu verdi — yani sonuçlarımız sağlam.

Jüriye: “Normallik Shapiro-Wilk ile kontrol edildi; ihlal durumunda Wilcoxon ile doğrulama yapıldı, sonuçlar tutarlıdır.”

5. Varyans Eşitliği Kontrolü (Levene Testi)

Günlük hayat: İki takımı karşılaştırıyorsun. A takımında herkes 70-80 arası puan alıyor (dar yayılım). B takımında biri 20, biri 100 alıyor (geniş yayılım). Bu iki takımın ortalamasını karşılaştırmak adil mi? Birinde herkes benzer, diğesinde uçurum var.

Neden önemli? ANOVA, karşılaştırılan grupların (5 Dreyfus seviyesi) içindeki yayılımın (varyansın) birbirine benzer olduğunu varsayar. Eğer bir grupta herkes benzer puan alırken diğ grupta çok dağınıksa, karşılaştırma yanıltıcı olur.

Ne yaptık? Levene testi ile 5 grubun varyanslarının eşit olduğunu doğruladık (tüm $p > .05$). ANOVA yapmaya hakkımız var.

Jüriye: “Levene testi ile varyans homojenliği sağlanmıştır.”

6. Kovaryans Homojenliği (Box’s M Testi)

Günlük hayat: Levene tek bir değişkene bakar. Ama Karma ANOVA’da birden fazla değişken var. Box’s M, “grupların değişkenler arası ilişki yapıları da benzer mi?” diye sorar. Yani sadece yayılım değil, değişkenlerin birbirleriyle nasıl ilişkilendiği de gruplar arasında benzer olmalı.

Neden önemli? Karma ANOVA çok değişkenli bir test. Eğer bir grupta “süre arttıkça yük de artıyor” ama başka grupta “süre arttıkça yük düşüyor” gibi farklı ilişki yapıları varsa, test yanıltıcı sonuç verebilir.

Ne yaptık? Box’s M testi ile kovaryans matrislerinin homojen olduğunu doğruladık.

Jüriye: “Box’s M testi ile kovaryans homojenliği sağlanmıştır.”

KATMAN C: Ana Analizler

Benzetme: Artık malzemeler temiz, mutfak hazır — şimdi yemeği pişirme zamanı. Bu katman tezin ana sorularını cevaplar.

7. Eşleştirilmiş t-Testi (H1, H2, H4)

Günlük hayat: Aynı kişiye iki farklı diyet uyguluyorsun: 1 ay A diyeti, 1 ay B diyeti. Sonra “hangisinde daha çok kilo verdi?” diye karşılaştırıyorsun. Farklı kişileri değil, aynı kişiyi iki durumda karşılaştırdığın için “eşleştirilmiş” deniyor.

Neden önemli? Tezde aynı 150 kişi hem Benzer Mod’u hem Tamamlayıcı Mod’u denedi. Farklı kişiler olsaydı “belki bir grup zaten daha iyiydi” diyebilirdik. Ama aynı kişi olduğu için fark gerçekten moddan kaynaklanıyor.

Ne yaptık? Her kişi için “Tamamlayıcı puanı – Benzer puanı” farkını hesapladık. Bu farkların ortalamasının sıfırdan farklı olup olmadığını test ettik. Sonuç: Öğrenme kazanımında Tamamlayıcı Mod 9.64 puan daha yüksek ($p < .001$).

Jüriye: “Within-subject tasarım olduğu için eşleştirilmiş örneklem t-testi uygulandı.”

8. Wilcoxon Testi (Sağlama)

Günlük hayat: t-testi “verilerin çan eğrisi gibi dağılmasını” ister. Bizim bazı verilerimiz tam çan eğrisi değildi. Wilcoxon, çan eğrisi gerektirmeyen bir alternatif. İkisini de yapıp “bakın ikisi de aynı sonucu veriyor” demek, sonuçların sağlam olduğunu kanıtlar.

Neden önemli? Jüri “normallik ihlali var, t-testiniz geçersiz” diyebilirdi. Wilcoxon’un da aynı sonucu vermesi bu eleştiriyi tamamen bloke eder.

Ne yaptık? Tüm değişkenlerde Wilcoxon da $p < .001$ verdi. Yani normallik ihlali sonuçları değiştirmemiş.

Jüriye: “Robustness check olarak Wilcoxon uygulandı, parametrik sonuçlarla tutarlıdır.”

9. İki Yönlü Karma ANOVA (H3 — Etkileşim)

Günlük hayat: “Kahve konsantrasyonu artırır mı?” sorusuna “evet” diyebilirsiniz. Ama asıl ilginç soru şu: “Kahvenin etkisi sabah mı akşam mı daha fazla?” İşte bu “etkileşim” sorusu. Yani iki şeyin birlikte etkisi, tek tek etkilerinden farklı mı?

Neden önemli? t-testi “Tamamlayıcı Mod genel olarak daha iyi” dedi. Ama “Acemilerde mi daha iyi, uzmanlarda mı?” sorusu çok daha değerli. Belki Tamamlayıcı Mod acemilere çok yarıyor ama uzmanları sıkıyor. Bu bilgi olmadan “herkese Tamamlayıcı Mod verin” demek yanlış olabilir.

Ne yaptık? Karma ANOVA ile Mod (within-subject: aynı kişi iki modu denedi) ve Dreyfus Seviyesi (between-subject: farklı kişiler farklı seviyelerde) faktörlerini aynı anda test ettik. Sonuç: Bilişsel yük ve görev süresinde anlamlı etkileşim bulundu ($\eta^2 = .139$ ve $.105$). Yani modun etkisi gerçekten seviyeye göre değişiyor.

Jüriye: “Mod $\times$ Seviye etkileşimi 2×5 karma ANOVA ile test edildi.”

10. Bonferroni Post-Hoc Testi

Günlük hayat: ANOVA “5 şehir arasında fiyat farkı var” diyor. Ama hangi şehirler arasında? İstanbul-Ankara mı, İstanbul-İzmir mi? Post-hoc testi tüm ikili karşılaştırmaları yaparak “tam olarak nerede fark var?” sorusunu cevaplar.

Neden önemli? 5 Dreyfus seviyesi var. ANOVA “seviyeler arasında fark var” dedi ama Acemi vs. Uzman mı farklı, yoksa Yetkin vs. Usta mı? Bunu bilmeden pratik öneri veremezsin.

Ne yaptık? 10 ikili karşılaştırma yaptık (5 seviye $\rightarrow$ 10 çift). Ama 10 karşılaştırma yapınca “şans eseri anlamlı çıkma” riski artar. Bonferroni bu riski kontrol eder: p-değerini karşılaştırma sayısına bölerek eşiği sıkılaştırır.

Jüriye: “Çoklu karşılaştırmalarda Tip I hata kontrolü için Bonferroni düzeltmesi uygulandı.”

11. Çoklu Regresyon (3 Yordama Modeli)

Günlük hayat: “Ev fiyatını ne belirler?” diye soruyorsun. Cevap: metrekare, kat, semt, yaş... hepsi birden etkiler. Regresyon, her birinin ne kadar etkili olduğunu ayrı ayrı söyler. “Metrekare %40 etkili, semt %30 etkili, yaş %15 etkili” gibi.

Neden önemli? t-testi ve ANOVA sadece “fark var mı?” sorusunu cevaplar. Ama “Kod kalitesini en çok ne etkiliyor? Mod mu, Seviye mi, Alan mı?” sorusu için regresyon lazım. Bu bilgi olmadan “neye odaklanmalıyız?” sorusu cevaplanamaz.

Ne yaptık? 3 model kurduk: (1) Kod Kalitesi = Mod + Seviye + Alan + Etkileşim, (2) Öğrenme = Mod + Seviye + TLX + Ön-test, (3) Bilişsel Yük = Mod + Seviye + Karmaşıklık + Süre. En güçlü model $R^2 = .82$ ile kod kalitesi modeliydi.

Jüriye: “Çoklu regresyon ile yordayıcı değişkenlerin göreceli katkıları belirlendi.”

KATMAN D: Etki Büyüklükleri

Benzetme: Doktora gittin, doktor “kolesterolünüz yüksek” dedi. Ama ne kadar yüksek? 201 mi (sınırdı) yoksa 350 mi (tehlikeli)? Etki büyüklüğü “ne kadar?” sorusunu cevaplar.

12. Cohen’s d (t-testleri için)

Günlük hayat: İki ilacı karşılaştırıyorsun. İkisi de “etkili” ($p < .05$). Ama biri ateşi 0.1 derece düşürüyor, diğeri 3 derece düşürüyor. p-değeri ikisinde de anlamlı ama pratikte biri işe yaramaz, diğeri hayat kurtarır. Cohen’s d bu farkı gösterir.

Neden önemli? 150 kişiyle çalışınca çok küçük farklar bile “istatistiksel olarak anlamlı” ($p < .05$) çıkabilir. Ama bu fark pratikte önemli mi? Cohen’s d bunu söyler: 0.2 = küçük (fark var ama zar zor), 0.5 = orta (fark belirgin), 0.8 = büyük (fark çok net). Bizim $d = 9.02$ çıkması muazzam bir etki.

Ne yaptık? Her t-testi sonucunun yanına Cohen’s d değerini koyduk. Örneğin bilişsel yükte $d = 9.02$ (devasa etki), öğrenme kazanımında $d = 5.13$ (çok büyük etki).

Jüriye: “Etki büyüklükleri Cohen’s d ile raporlanmış olup tüm karşılaştırmalarda büyük etki tespit edilmiştir.”

13. Kısmi Eta-Kare / η^2 (ANOVA için)

Günlük hayat: “Sınıftaki not farklılıklarının ne kadarı öğretmenden, ne kadarı öğrencinin çalışmasından, ne kadarı şanstın kaynaklanıyor?” η^2 bu soruyu cevaplar. Örneğin $\eta^2 = .14$ demek “toplam değişimin %14’ü bu faktörden kaynaklanıyor” demek.

Neden önemli? ANOVA “etkileşim anlamlı” dedi ($p < .05$). Ama bu etkileşim toplam değişimin %1’ini mi açıklıyor yoksa %20’sini mi? η^2 bunu gösterir. Yorum: .01 = küçük, .06 = orta, .14 = büyük.

Ne yaptık? Karma ANOVA sonuçlarına η^2 ekledik. Örneğin Mod $\times$ Seviye etkileşimi bilişsel yükte $\eta^2 = .139$ (büyük etki sınırında), görev süresinde $\eta^2 = .105$ (orta-büyük etki).

Jüriye: “Etkileşim etkisi kısmi eta-kare ile .139 olarak hesaplanmış olup büyük etki kategorisindedir.”

14. R^2 — Belirtme Katsayısı (Regresyon için)

Günlük hayat: Hava durumu tahmini %80 doğruysa iyi bir model. %20 doğruysa kötü. R^2 modelin “doğruluk yüzdesi” gibidir. $R^2 = .82$ demek “modelimiz kod kalitesindeki değişimin %82’sini açıklayabiliyor” demek.

Neden önemli? Regresyon katsayıları (β) tek tek anlamlı olabilir ama model bütün olarak zayıf olabilir. R^2 modelin genel başarısını tek bir sayıyla özetler.

Ne yaptık? Kod kalitesi modelinde $R^2 = .82$ bulduk. Bu, eğitim araştırmalarında çok yüksek bir açıklama gücüdür (genelde .30-.50 arası “iyi” kabul edilir).

Jüriye: “Model, bağımlı değişkendeki varyansın %82’sini açıklamaktadır.”

Tek Sayfa Özet

#	Test	Günlük Hayat Karşılığı	Tezde Ne İçin?
1	MCAR	Boş bırakanlar rastgele mi?	Veri silme meşruiyeti
2	Z-skoru	Sınıfın en uç öğrencisi	Tek boyutlu outlier
3	Mahalanobis	Her şeyde “biraz” uç olan	Çok boyutlu outlier
4	Shapiro-Wilk	Notlar çan eğrisi mi?	Parametrik test hakkı
5	Levene	Grupların yayılımı benzer mi?	ANOVA ön koşulu
6	Box's M	Grupların ilişki yapısı benzer mi?	Karma ANOVA ön koşulu
7	Eşl. t-testi	Aynı kişi, iki durum, fark var mı?	H1, H2, H4
8	Wilcoxon	t-testinin sigortası	Normallik ihlali sağlaması
9	Karma ANOVA	Etkileşim: “kime göre değişiyor?”	H3
10	Bonferroni	“Tam olarak hangi gruplar farklı?”	Post-hoc
11	Regresyon	“Ne, ne kadar etkili?”	Yordama modelleri
12	Cohen's d	Fark büyük mü küçük mü?	t-testi etki büyüklüğü
13	η^2	Faktör ne kadar açıklıyor?	ANOVA etki büyüklüğü
14	R^2	Model ne kadar başarılı?	Regresyon başarısı